

第 5 章 减少方差的统计方法

5.1 估计定积分例子

5.1.1 随机投点法

设 $0 \leq f(x) \leq 1$, 积分值 I 就是曲线 $f(x)$ 下方 $x = 0$ 和 $x = 1$ 之间的曲边梯形的面积. 为求积分值 I , 我们首先构造随机投点模型, 即向正方形 $\{0 \leq x \leq 1, 0 \leq y \leq 1\}$ 内随机投点 $\{\xi_i, \eta_i\} (i = 1, 2, \dots)$, 其中 $\xi_i \sim U(0, 1), \eta_i \sim U(0, 1)$, 且相互独立.

若第 i 个点落入曲边梯形内, 即满足条件 $\eta_i \leq f(\xi_i)$, 则称第 i 次试验成功. 随机投点试验成功的概率 p 为:

$$p = P\{\eta \leq f(\xi)\} = \int_0^1 \int_0^{f(x)} dy dx = \int_0^1 f(x) dx = I$$

因此 $I = \int_0^1 f(x) dx = p$. 在随机投点试验的模型下, 定积分值 I 就是试验成功的概率 p .

重复进行随机投点试验, 记录试验次数 N 和成功次数 M , 用频率 M/N 作为概率 p 的估计值, 即可得出定积分值 I 的近似解:

$$I \approx M/N \quad (3.2)$$

记 $\theta_1 = M/N$, 它是成功概率 p 的估计量. 在 N 次试验中, 成功次数 M 服从二项分布 $B(N, p)$, 故有

$$E(M) = Np, \text{Var}(M) = Np(1-p);$$

因此

$$E(\theta_1) = p, \text{Var}(\theta_1) = \frac{1}{N}p(1-p). \quad (3.3)$$

可见 θ_1 是 p 的无偏估计量.

算法3.1(随机投点法)

- ①赋初值:试验次数 $n = 0$, 成功次数 $m = 0$; 规定投点试验的总次数 N ;
- ②产生两个相互独立的均匀随机数 ξ, η ; 置 $n = n + 1$;
- ③判断 $n \leq N$ 是否成立, 若成立转 ④, 否则停止试验, 转 ⑤;
- ④判断条件 $\eta \leq f(\xi)$ 是否成立, 若成立置 $m = m + 1$, 然后转 ②; 否则转 ②;
- ⑤计算 $\theta_1 = m/N$, 则 θ_1 为 I 的近似解.

对一般区间 $[a, b]$ 上定积分 $I = \int_a^b f(x)dx$ 的计算, 只需做线性变换, 即可化为 $[0, 1]$ 区间上的积分. 设 $f(x)$ 在 $[a, b]$ 上有界: $c \leq f(x) \leq d$, 为了化一般区间上的积分为 $[0, 1]$ 区间上的积分, 且被积函数值在 $[0, 1]$ 之间, 令 $x = (b-a)u + a$, 则有

$$\begin{aligned}\int_a^b f(x)dx &= \int_0^1 [f(a + (b-a)u) - c + c](b-a)du \\ &= \int_0^1 (b-a)(d-c) \frac{f(a + (b-a)u) - c}{d-c} du + c(b-a) \\ &= S_0 \int_0^1 \varphi(u)du + c(b-a),\end{aligned}$$

其中 $\varphi(u) = \frac{1}{d-c}[f(a + (b-a)u) - c]$, $S_0 = (b-a)(d-c)$. 因 $c \leq f(x) \leq d$, 故有 $0 \leq \varphi(u) \leq 1$ (当 $u \in (0, 1)$ 时). 故只需求解 $[0, 1]$ 区间上的标准定积分值, 即可得到一般区间 $[a, b]$ 上的定积分值. 或者直接构造向长方形区域 $\{a \leq x \leq b, c \leq y \leq d\}$ 随机投点的试验模型. 这时定积分值 I 为

$$I = \int_a^b f(x)dx = pS_0 + c(b-a),$$

其中 $S_0 = (b-a)(d-c)$ 是长方形的面积.

5.1.2 平均值估计法

(2)平均值估计法

设随机变量 $R \sim U(0, 1)$, 则 $Y = f(R)$ 的数学期望为

$$E(f(R)) = \int_0^1 f(x)dx = I \quad (3.4)$$

这表明积分值 I 是随机变量 $Y = f(R)$ 的数学期望. 可以用数学期望的估计值作为 I 的近似解. 这时只需产生均匀随机数 r_1, r_2, \dots, r_N , 则

$$I = E(f(R)) \approx \frac{1}{N} \sum_{i=1}^N f(r_i) \triangleq \theta_2, \quad (3.5)$$

θ_2 是数学期望 $E(f(R))$ 的无偏估计量. 随机变量 $Y = f(R)$ 的方差为 $Var(Y) = \int_0^1 (f(x) - I)^2 dx$, 故而

$$Var(\theta_2) = Var(\bar{Y}) = \frac{1}{N} Var(Y).$$

可以证明: $Var(\theta_2) \leq Var(\theta_1)$.

事实上, 由于有 $Var(\theta_1) = \frac{1}{N} p(1-p) = \frac{1}{N} I(1-I)$, 而且有 $Var(\theta_2) = \frac{1}{N} \int_0^1 (f(x) - I)^2 dx = \frac{1}{N} [\int_0^1 f^2(x) dx - I^2]$, 因此 $Var(\theta_2) - Var(\theta_1) = \frac{1}{N} [\int_0^1 f^2(x) dx - I]$. 因为已假设 $0 \leq f(x) \leq 1$, 且 $\int_0^1 f(x) dx = I$, 所以 $I \geq \int_0^1 f^2(x) dx$, 可见

$$Var(\theta_2) - Var(\theta_1) \leq 0.$$

算法3.2(平均值估计法)

- ①产生 $[0, 1]$ 区间的均匀随机数 r_1, r_2, \dots, r_N ;
- ②计算 $f(r_i) (i = 1, 2, \dots, N)$;
- ③令 $\theta_2 = \frac{1}{N} \sum_{i=1}^N f(r_i)$, 则 θ_2 为积分值 I 的近似解.

5.2 对偶变量的应用

首先给出对偶变量的定义。

定义5.2.1 (对偶变量) 对于变量 X , 如果变量 $Y = g(X)$ 与变量 X 均值和方差分别相同, 也就是 $E(X) = E(Y)$, $Var(X) = Var(Y)$, 且 $Cov(X, Y) \leq 0$, 则 Y 称为 $E(X)$ 通过 $0.5E(X+Y)$ 估计的对偶变量。

1、对偶变量估计 $E(X)$ 的思想

如果 X_1, X_2, \dots, X_n 为样本数据, 则 $\mu = E(X)$ 的估计为 $\hat{\mu}_1 = n^{-1} \sum_{i=1}^n X_i$. 对偶变量估计的思想为: 假设存在 X 的对偶变量 $Y = g(X)$, 则 $E(X) = 0.5E(X+Y)$. 此时 $E(X)$ 的估计为

$$\hat{\mu}_2 = \frac{1}{2n} \sum_{i=1}^n (X_i + Y_i) = \frac{1}{2n} \sum_{i=1}^n (X_i + g(X_i)).$$

对估计 $\hat{\mu}_1$ 和 $\hat{\mu}_2$, 不难得到 $\text{Var}(\hat{\mu}_1) = n^{-1}\text{Var}(X)$ 和 $\text{Var}(\hat{\mu}_2) = (2n)^{-1}\text{Var}(X + Y) = (2n)^{-1}\text{Var}(X + g(X))$. 因此只要 $2^{-1}\text{Var}(X + g(X)) \leq \text{Var}(X)$, 则 $\hat{\mu}_2$ 的方差没有 $\hat{\mu}_1$ 的方差大. 注意到 $Y = g(X)$ 和 X 的方差相同, 可得

$$\begin{aligned} & 2^{-1}\text{Var}(X + g(X)) - \text{Var}(X) \\ = & 2^{-1}(\text{Var}(X) + \text{Var}(g(X)) + 2\text{Cov}(X, g(X)) - 2\text{Var}(X)) = \text{Cov}(X, g(X)). \end{aligned}$$

只要 $\text{Cov}(X, g(X)) \leq 0$, 基于对偶变量得到的估计 $\hat{\mu}_2$ 比平均值估计 $\hat{\mu}_1$ 方差小. 基于对偶变量 Y 得到的估计 $\hat{\mu}_2$ 称为对偶变量法.

下面的定理说明如果 X 是 $U(0, 1)$ 均匀分布, 则很容易找到符合条件的对偶变量 $g(X)$.

定理5.2.1 如果 X 是 $U(0, 1)$ 均匀分布, 则 $g(X) = 1 - X$ 和 X 同分布, 且满足 $\text{Cov}(X, g(X)) < 0$.

证明: 由随机变量变换法可以求得随机变量 $g(X)$ 的密度函数为

$$f(x) = 1 \cdot \mathbb{I}_{\{0 \leq 1-x \leq 1\}} = 1 \cdot \mathbb{I}_{\{0 \leq x \leq 1\}},$$

也就是 $U(0, 1)$ 均匀分布的密度函数. 直接计算可得

$$\begin{aligned} \text{Cov}(X, g(X)) &= E[Xg(X)] - E(X)E(g(X)) \\ &= \int_0^1 x(1-x)dx - \frac{1}{2^2} \\ &= \frac{1}{2} - \frac{1}{3} - \frac{1}{4} < 0. \end{aligned}$$

模拟验证1, 根据 $U(0, 1)$ 上的独立样本 u_1, u_2, \dots, u_n , 采用对偶变量的方法, 估计 EU^2 , 这里 U 是 $(0, 1)$ 上的均匀分布. 这里 $n = 100$.

```
n=100
hat_mu1<-NULL
hat_mu2<-NULL
for (i in 1:1000){
  data=runif(n,0,1)
  X=data^2
  hat_mu1[i]=mean(X)
```

```

Y=(1-data)^2
hat_mu2[i]=0.5*mean(X+Y)
}
c(mean(hat_mu1),mean(hat_mu2),var(hat_mu1),var(hat_mu2))

```

模拟验证2, 假设 X 服从正态分布 $N(\mu, \sigma^2)$, 基于样本 x_1, x_2, \dots, x_n , 采用对偶变量的方法估计 $E(X)$. 这里 $n = 100$, $\mu = 5$, $\sigma = 2$.

```

library(MASS)
n=100
hat_mu1<-NULL
hat_mu2<-NULL
Mu=c(5,5)
Sigma=matrix(c(2,0.8,0.8,2),ncol=2,nrow=2,byrow=T)
for (i in 1:1000){
Data=mvnrnorm(n,Mu,Sigma)
X=Data[,1]
hat_mu1[i]=mean(X)
Y=Data[,2]
hat_mu2[i]=0.5*mean(X+Y);
}
c(mean(hat_mu1),mean(hat_mu2),var(hat_mu1),var(hat_mu2))

```

2、对偶变量估计 $Ef(U)$

假设 U_1, U_2, \dots, U_n 为来自 $U(0, 1)$ 的均匀分布样本, 则 $\mu = Ef(U)$ 的估计为 $\hat{\mu}_1 = (2n)^{-1} \sum_{i=1}^{2n} f(U_i)$ 。如果 $f(\cdot)$ 是单调函数, 则对偶变量 $f(1-U)$ 与 $f(U)$ 同分布且 $\text{Cov}(f(1-U), f(U)) \leq 0$ (具体证明见定理5.2.2). 则对偶估计

$$\hat{\mu}_2 = \frac{1}{2n} \sum_{i=1}^n (f(U_i) + f(1-U_i))$$

比估计 $\hat{\mu}_1$ 更好。

定理5.2.2 设 f 为单调函数, $U \sim U(0, 1)$, 则 $\text{Cov}(f(U), f(1-U)) \leq 0$ 。

证明: 不妨设 f 为单调增函数, 令 $g(x) = -f(1-x)$, 则 g 为单调增函数, 现在证明定理等价于证明 $\text{Cov}(f(U), g(U)) \geq 0$. 因为 f 和 g 都是单调增函数, 则对任意的 x 和 y 有

$$[f(x) - f(y)][g(x) - g(y)] \geq 0.$$

对任何随机变量 X 和 Y , $[f(X) - f(Y)][g(X) - g(Y)] \geq 0$, 取期望得

$$E\{[f(X) - f(Y)][g(X) - g(Y)]\} \geq 0$$

或者等价于

$$E[f(X)g(X)] + E[f(Y)g(Y)] \geq E[f(X)g(Y)] + E[f(Y)g(X)]. \quad (5.2.1)$$

(5.2.1)式对于任意的随机变量 X, Y 以及任意的单调函数 $f(x)$ 和 $g(x) = -f(1-x)$ 均成立。特别地, 当随机变量 X 和 Y 独立同分布时有

$$E[f(X)g(X)] = E[f(Y)g(Y)]$$

$$E[f(X)g(Y)] = E[f(Y)g(X)] = E[f(X)]E[g(Y)],$$

此时(5.2.1)式化为

$$2E[f(X)g(X)] \geq 2E[f(X)]E[g(Y)] = 2E[f(X)]E[g(X)]$$

则 $\text{Cov}(f(U), g(U)) = E[f(U)g(U)] - E[f(U)]E[g(U)] \geq 0$, 定理证毕。

为了将定理5.2.2推广到多变量的情形, 下面给出一个具有启发性的定理, 而将定理5.2.2在多变量情形下的推广作为其重要推论给出。

定理5.2.3 设随机变量 X_1, X_2, \dots, X_n 相互独立, 函数 $f(X) = f(X_1, X_2, \dots, X_n)$ 和 $g(X) = g(X_1, X_2, \dots, X_n)$ 关于每个自变量 $X_i, i = 1, 2, \dots, n$ 单调增, 则

$$E[f(X)g(X)] \geq E[f(X)]E[g(X)].$$

证明: 对变量个数 n 做归纳法。由定理5.2.2的证明过程知, 当 $n = 1$ 时定理成立。假设定理对 $n-1$ 个变量的情况下成立, 则对于 n 个变量的情况, 可得

$$\begin{aligned} & E[f(X)g(X)|X_n = x_n] \\ &= E[f(X_1, \dots, X_{n-1}, x_n)g(X_1, \dots, X_{n-1}, x_n)|X_n = x_n] \\ &= E[f(X_1, \dots, X_{n-1}, x_n)g(X_1, \dots, X_{n-1}, x_n)] \quad \text{根据独立性} \\ &\geq E[f(X_1, \dots, X_{n-1}, x_n)]E[g(X_1, \dots, X_{n-1}, x_n)] \quad \text{根据归纳假设} \\ &= E[f(X)|X_n = x_n]E[g(X)|X_n = x_n] \end{aligned}$$

由于上面的论述对于任意 x_n 都成立, 因此

$$E[f(X)g(X)|X_n] \geq E[f(X)|X_n]E[g(X)|X_n],$$

两端取期望, 由重期望公式得

$$\begin{aligned} E[f(X)g(X)] &\geq E\{E[f(X)|X_n]E[g(X)|X_n]\} \\ &\geq E[f(X)]E[g(X)]. \end{aligned}$$

后一个不等式成立是因为 $E[f(X)|X_n]$ 和 $E[g(X)|X_n]$ 都是 X_n 的单调增函数, 根据 $n = 1$ 时的结论可得

$$\begin{aligned} E\{E[f(X)|X_n]E[g(X)|X_n]\} &\geq E\{E[f(X)|X_n]\}E\{E[g(X)|X_n]\} \\ &= E[f(X)]E[g(X)]. \end{aligned}$$

故定理在 n 个变量的情况下也成立, 由归纳原理定理证毕。

定理5.2.4 设 $h(x_1, x_2, \dots, x_n)$ 是关于每个自变量单调的函数, U_1, U_2, \dots, U_n 相互独立, 则 $\text{Cov}(h(U_1, U_2, \dots, U_n), h(1 - U_1, 1 - U_2, \dots, 1 - U_n)) \leq 0$ 。

证明: 不失一般性, 由于 U_1, U_2, \dots, U_n 之间独立同分布, 通过重新定义 h , 可以假定 h 是其前 r 个自变量的单调增函数, 后 $n - r$ 个自变量的单调减函数。因此, 令

$$\begin{aligned} f(x_1, \dots, x_n) &= h(x_1, \dots, x_r, 1 - x_{r+1}, \dots, 1 - x_n) \\ g(x_1, \dots, x_n) &= -h(1 - x_1, \dots, 1 - x_r, x_{r+1}, \dots, x_n) \end{aligned}$$

由此可得 f 和 g 都是关于每个自变量的单调增函数。根据定理5.2.3 可得

$$\text{Cov}(f(U_1, \dots, U_n), g(U_1, \dots, U_n)) \geq 0$$

这等价于

$$\begin{aligned} \text{Cov}(h(U_1, \dots, U_r, 1 - U_{r+1}, \dots, 1 - U_n), \\ h(1 - U_1, \dots, 1 - U_r, U_{r+1}, \dots, U_n)) \leq 0. \end{aligned} \quad (5.2.2)$$

而随机向量 $(h(U_1, \dots, U_n), h(1 - U_1, \dots, 1 - U_n))$ 的联合分布与随机向量

$$(h(U_1, \dots, U_r, 1 - U_{r+1}, \dots, 1 - U_n), h(1 - U_1, \dots, 1 - U_r, U_{r+1}, \dots, U_n))$$

的联合分布相同, 由(5.2.2), 定理证毕。

事实上, 定理5.2.4的结果可以推广。如果 $(X_i, Y_i), i = 1, 2, \dots, n$ 独立, 且 X_i 和 Y_i 是对偶变量且负相关, $h(x_1, x_2, \dots, x_n)$ 关于每个自变量单调不减, 则 $\text{Cov}(h(X_1, X_2, \dots, X_n), h(Y_1, Y_2, \dots, Y_n)) \leq 0$ 。对于期望 $Eh(X_1, X_2, \dots, X_n)$, 可以引入对偶变量 $h(Y_1, Y_2, \dots, Y_n)$, 相对于平均值估计法, 降低估计的方差。例如, 要估计 $\theta = Eh(X_1, X_2, \dots, X_n)$, 如果 $X_i \sim N(\mu_i, \sigma_i^2)$ 相互独立, 相应的对偶变量可以选为 $Y_i = 2\mu_1 - X_i$ 。因此可以根据对偶变量 $h(Y_1, Y_2, \dots, Y_n)$ 降低估计 $\hat{\theta}$ 的方差。

引理5.2.1 如果 X 的分布函数 $F(x)$ 逆变换存在, 则对 $E(X) = E(F^{-1}(U))$ 的估计, 可以通过引入对偶变量 $F^{-1}(1 - U)$, 根据 $E(X) = 0.5E(F^{-1}(U) + F^{-1}(1 - U))$ 估计降低估计方差。

根据引理5.2.1, 对随机样本 U_1, U_2, \dots, U_n , 利用对偶变量对 $\mu = E(X)$ 的估计 $\hat{\mu}_2 = (2n)^{-1} \sum_{i=1}^n \{F^{-1}(U_i) + F^{-1}(1 - U_i)\}$ 。 $\mu = E(X)$ 的方差比估计 $\hat{\mu}_1 = n^{-1} \sum_{i=1}^n F^{-1}(U_i)$ 的方差小。

上述所提出的对偶变量估计, X 和 Y 的权重都是0.5, 一个很自然的问题是通过 $E(X) = E(\alpha X + (1 - \alpha)Y)$, $\alpha \in [0, 1]$ 估计 $E(X)$, 也就是 $\hat{\mu}_\alpha = n^{-1} \sum_{i=1}^n (\alpha X_i + (1 - \alpha)Y_i)$ 。容易验证当 $\alpha = \text{Cov}(Y, Y - X) / \text{Var}(Y - X)$ 时 $\text{Var}(\hat{\mu}_\alpha)$ 最小。(验证一下最后一句话是否正确??)。

例5.2.1 利用对偶变量法, 根据 $[0, 1]$ 均匀随机样本 U_1, U_2, \dots, U_n , 估计 $I = \int_0^1 e^t dt = E(e^U)$, 并计算估计量的方差。

上例中 $X = e^U$, 选对偶变量 $Y = e^{1-U}$, 则用对偶变量法估计 I 为

$$\hat{I} = \frac{1}{2n} \sum_{i=1}^n e^{U_i} + e^{1-U_i}, \quad (5.2.3)$$

方差为

$$\text{Var}(\hat{I}) = \frac{1}{2n} \text{Var}(e^U) + \text{Cov}(e^U, e^{1-U}) = \frac{1}{n} \left(-\frac{3}{4}e^2 + \frac{5}{2}e - \frac{5}{4} \right) \approx \frac{0.00391}{n}. \quad (5.2.4)$$

样本量 $n = 20$ 的情况下, 用对偶变量法估计 $E(e^U)$ 的程序如下:

n=20


```

hat_mu1<-NULL
hat_mu2<-NULL
for (i in 1:1000){
  U=runif(n,0,1)
  X=exp(U)
  hat_mu1[i]=mean(X)
  Y=exp(1-U)
  hat_mu2[i]=0.5*mean(X+Y);
}
c(mean(hat_mu1),mean(hat_mu2),var(hat_mu1),var(hat_mu2))

```

例5.2.2 利用对偶变量法，估计 $I = Ee^{X_1+X_2}$ ，这里 $X_1 \sim N(\mu_1, \sigma_1^2)$ 和 $X_2 \sim N(\mu_2, \sigma_2^2)$ 独立。)

作业：用对偶变量法给出参数 I 的估计。

5.3 控制变量法的应用

首先给出控制变量的定义。

定义5.3.1 (控制变量) 对于变量 X ，如果变量 Y 的期望为0，且 $\text{Var}(Y) + 2\text{Cov}(X, Y) \leq 0$ ，则称 Y 为 $E(X)$ 通过 $E(X + Y)$ 估计的控制变量。

本节通过控制变量 Y 降低期望 $\mu = EX$ 的估计。从 X 中抽取 n 个独立样本值 X_1, X_2, \dots, X_n ，则平均值估计为 $\hat{\mu}_1 = n^{-1} \sum_{i=1}^n X_i$ 。注意到 $E(Y) = 0$ ，则 $\mu = E(X + Y)$ 。基于样本 X_1, X_2, \dots, X_n ，如果相应的可得 Y_1, Y_2, \dots, Y_n ，则用控制变量估计 $\mu = EX$ 为 $\hat{\mu}_2 = n^{-1} \sum_{i=1}^n (X_i + Y_i)$ 。简单计算可得两个估计的方差分别为

$$\text{Var}(\hat{\mu}_1) = n^{-1} \text{Var}(X), \quad \text{Var}(\hat{\mu}_2) = n^{-1} (\text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)).$$

只要 $\text{Var}(Y) + 2\text{Cov}(X, Y) \leq 0$ ，则 $\text{Var}(\hat{\mu}_2) \leq \text{Var}(\hat{\mu}_1)$ 。因此控制变量 Y 可以降低 $E(X)$ 估计的方差。

注意到 $E(X) = E(X + \beta Y)$ ，可以通过 $\hat{\mu}_\beta = n^{-1} \sum_{i=1}^n (X_i + \beta Y_i)$ 估计 $E(X)$ ，